



CURSO: MINERÍA DE DATOS
MAESTRÍA EN EXPLOTACIÓN DE DATOS Y DESCUBRIMIENTO DE CONOCIMIENTO

LABORATORIO V: Valores Faltantes (Preprocesamiento)

INTRODUCCIÓN

Esta práctica de laboratorio tiene como objetivo avanzar en la exploración de las técnicas de valores faltantes -análisis e imputación- de la etapa de Preprocesamiento, del Proceso de Descubrimiento de Conocimiento.

Para la exploración de estos temas, se utilizará el IDE R-Studio del lenguaje de programación R, a efectos de ejercitar los conceptos abordados en las clases teóricas.

CONSIGNAS

A partir del dataset *auto-mpg.data-original.txt*¹, se solicita trabajar sobre las siguientes consignas:

1. SOBRE LOS DATOS

- a. Cargue² y explore el dataset: explique en qué consiste el mismo y qué características posee.
- b. Con las técnicas abordadas en las prácticas de laboratorio anteriores, realice un breve análisis exploratorio para identificar cual es la distribución de sus variables y si existe relación entre las mismas.

2. VALORES FALTANTES

- a. Verifique la existencia de datos faltantes en cada uno de los atributos ¿Existen datos faltantes en algún atributo? ¿En cuál/es? Indague sobre la proporción de datos que aparecen como faltante en la distribución.
- b. Aplique las técnicas de tratamiento de datos faltantes abordadas en clase (registros completos, sustitución por la media, e imputación por regresiones, hot deck³ y MICE).

¹ Disponibles en: <https://archive.ics.uci.edu/ml/datasets/Auto+MPG>

² Explore la instrucción *read.table()*.

³ Algunas de las librerías disponibles para hot deck son *VIM (recomendada)*, *HotDeckImputation* y *hot.deck*.



CURSO: MINERÍA DE DATOS

MAESTRÍA EN EXPLOTACIÓN DE DATOS Y DESCUBRIMIENTO DE CONOCIMIENTO

- c. Analice gráficamente⁴ y analíticamente la variación en la distribución de datos de la variable estudiada. ¿Qué técnica de imputación afecta menos la distribución original?

Referencias sugeridas:

García, S., Luengo, J., & Herrera, F. (2016). Data preprocessing in data mining. Springer.

M. Brown, J.Kros (2003). Data mining and the impact of missing values.

Han, J., Pei, J., & Kamber, M. (2011). Data mining: concepts and techniques. Elsevier.

An Introduction to R: <https://cran.r-project.org/doc/manuals/r-release/R-intro.pdf>

⁴ Se recomienda un gráfico de densidad, puede utilizar la instrucción *density*.